CAPITULO 8. INTRODUCCION AL MÉTODO DE SIMULACIÓN MONTE CARLO

Objetivos del Capítulo

- Introducir los conceptos e ideas clave de la simulación Monte Carlo.
- Introducirse en las capacidades que ofrece Excel en los campos de modelado y simulación.
- Conocer algunas aplicaciones de la simulación Monte Carlo.

8.0 Introducción

Bajo el nombre de Método Monte Carlo o Simulación Monte Carlo se agrupan una serie de procedimientos que analizan distribuciones de variables aleatorias usando simulación de números aleatorios.

El Método de Monte Carlo da solución a una gran variedad de problemas matemáticos haciendo experimentos con muestreos estadísticos en una computadora. El método es aplicable a cualquier tipo de problema, ya sea estocástico o determinístico.

Generalmente en estadística los modelos aleatorios se usan para simular fenómenos que poseen algún componente aleatorio. Pero en el método Monte Carlo, por otro lado, el objeto de la investigación es el objeto en sí mismo, un suceso aleatorio o pseudo-aleatorio se usa para estudiar el modelo.

A veces la aplicación del método Monte Carlo se usa para analizar problemas que no tienen un componente aleatorio explícito; en estos casos un parámetro determinista del problema se expresa como una distribución aleatoria y se simula dicha distribución. Un ejemplo sería el famoso problema de las Agujas de Bufón.

La simulación de Monte Carlo también fue creada para resolver integrales que no se pueden resolver por métodos analíticos, para solucionar estas integrales se usaron números aleatorios. Posteriormente se utilizó para cualquier esquema que emplee números aleatorios, usando variables aleatorias con distribuciones de probabilidad conocidas, el cual es usado para resolver ciertos problemas estocásticos y determinísticos, donde el tiempo no juega un papel importante.

La simulación de Monte Carlo es una técnica que combina conceptos estadísticos (muestreo aleatorio) con la capacidad que tienen los ordenadores para generar números pseudo-aleatorios y automatizar cálculos.

8.1 Inicios del Método de Monte Carlo

El método fue llamado así por el principado de Mónaco por ser ``la capital del juego de azar'', al tomar una ruleta como un generador simple de números aleatorios. El nombre y el desarrollo sistemático de los métodos de Monte Carlo datan aproximadamente de 1944 con el desarrollo de la computadora. Sin embargo hay varias instancias (aisladas y no desarrolladas) en muchas ocasiones anteriores a 1944.

El uso real de los métodos de Monte Carlo como una herramienta de investigación, proviene del trabajo de la bomba atómica durante la Segunda Guerra Mundial. Este trabajo involucraba la simulación directa de problemas probabilísticos de hidrodinámica concernientes a la difusión de neutrones aleatorios en material de fusión.

Aún en la primera etapa de estas investigaciones, John von Neumann y Stanislao Ulam refinaron esta curiosa ``Ruleta rusa'' y los métodos``de división''. Sin embargo, el desarrollo sistemático de estas ideas tuvo que esperar el trabajo de Harris y Herman Kahn en 1948. Aproximadamente en el mismo año, Fermi, Metropolos y Ulam obtuvieron estimadores para los valores característicos de la ecuación de Schrödinger para la captura de neutrones a nivel nuclear.

Alrededor de 1970, los desarrollos teóricos en complejidad computacional comienzan a proveer mayor precisión y relación para el empleo del método Monte Carlo. La teoría identifica una clase de problemas para los cuales el tiempo necesario para evaluar la solución exacta al problema crece con la clase, al menos exponencialmente con M. La cuestión a ser resuelta era si MC pudiese o no estimar la solución al problema de tipo intratable con una adecuación estadística acotada a una complejidad temporal polinomial en M. Karp(1985) muestra esta propiedad para estimar en una red plana multiterminal con arcos fallidos aleatorios. Dyer(1989) utiliza MC para estimar el volumen de un convex body en el espacio Euclidiano M-dimensional. Broder(1986), Jerrum y Sinclair (1988) establecen la propiedad para estimar la persistencia de una matriz o en forma equivalente, el número de matching perfectos en un grafo bipartito.

Los orígenes de esta técnica están ligados al trabajo desarrollado por Stan Ulam y John Von Neumann a finales de los 40 en el laboratorio de Los Alamos, cuando investigaban el movimiento aleatorio de los neutrones. En años posteriores, la simulación de Monte Carlo se ha venido aplicando a una infinidad de ámbitos como alternativa a los modelos matemáticos exactos o incluso como único medio de estimar soluciones para problemas complejos. Así, en la actualidad es posible encontrar modelos que hacen uso de simulación MC en las áreas informática, empresarial, económica, industrial e incluso social. En otras palabras, la simulación de Monte Carlo está presente en todos aquellos ámbitos en los que el comportamiento aleatorio o probabilístico desempeña un papel fundamental - precisamente, el nombre de Monte Carlo proviene de la famosa ciudad de Mónaco, donde abundan los casinos de juego y donde el azar, la probabilidad y el comportamiento aleatorio conforman todo un estilo de vida.

Son muchos los autores que han apostado por utilizar hojas de cálculo para realizar simulación MC. La potencia de las hojas de cálculo reside en su universalidad, en su facilidad de uso, en su capacidad para recalcular valores y, sobre todo, en las posibilidades que ofrece con respecto al análisis de escenarios ("what-if analysis"). Las últimas versiones de Excel incorporan, además, un lenguaje de programación propio, el Visual Basic for Applications, con el cual es posible crear auténticas aplicaciones de simulación destinadas al usuario final. En el mercado existen de hecho varios complementos de Excel (Add-Ins) específicamente diseñados para realizar simulación MC, siendo los más conocidos: @Risk, Crystall Ball, Insight.xla, SimTools.xla, etc..

8.2 Simulación: Método Monte Carlo

Simulación: es el proceso de diseñar y desarrollar un modelo computarizado de un sistema o proceso y conducir experimentos con este modelo con el propósito de entender el comportamiento del sistema o evaluar varias estrategias con las cuales se puede operar el sistema.

- **Modelo de simulación:** conjunto de hipótesis acerca del funcionamiento del sistema expresado como relaciones matemáticas y/o lógicas entre los elementos del sistema.

- **Proceso de simulación:** ejecución del modelo a través del tiempo en un ordenador para generar muestras representativas del comportamiento.

8.2.1 Métodos de simulación

- **Simulación estadística o Monte Carlo**: Está basada en el muestreo sistemático de variables aleatorias.

- **Simulación continua**: Los estados del sistema cambian continuamente su valor. Estas simulaciones se modelan generalmente con ecuaciones diferenciales.

- **Simulación por eventos discretos**: Se define el modelo cuyo comportamiento varía en instantes del tiempo dados. Los momentos en los que se producen los cambios son los que se identifican como los eventos del sistema o simulación.

- **Simulación por autómatas celulares**: Se aplica a casos complejos, en los que se divide al comportamiento del sistema en subsistemas más pequeños denominadas células. El resultado de la simulación está dado por la interacción de las diversas células.

8.2.2 Etapas del proceso de simulación

- Definición, descripción del problema. Plan.

- Formulación del modelo.
- Programación.
- Verificación y Validación del modelo.
- Diseño de experimentos y plan de corridas.
- Análisis de resultados

8.2.3 Diagrama de flujo del modelo de simulación

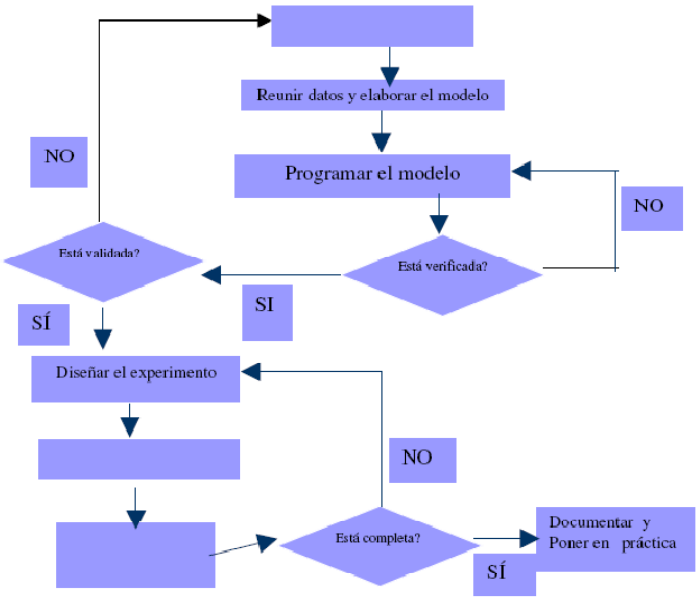

8.3 Algoritmos

El algoritmo de Simulación Monte Carlo Crudo o Puro está fundamentado en la generación de números aleatorios por el método de Transformación Inversa, el cual se basa en las distribuciones acumuladas de frecuencias:

- Determinar la/s Variable Aleatoria y sus distribuciones acumuladas(F)
- Iterar tantas veces como muestras necesitamos
    - Generar un número aleatorio
    - Uniforme ∈ (0,1).
    - Determinar el valor de la V.A. para el número aleatorio generado de acuerdo a las clases que tengamos.
- Calcular media, desviación estándar error y realizar el histograma.
- Analizar resultados para distintos tamaños de muestra.

Otra opción para trabajar con Monte Carlo, cuando la variable aleatoria no es directamente el resultado de la simulación o tenemos relaciones entre variables es la siguiente:

- Diseñar el modelo lógico de decisión
- Especificar distribuciones de probabilidad para las variables aleatorias relevantes.
- Incluir posibles dependencias entre variables.
- Muestrear valores de las variables aleatorias.
- Calcular el resultado del modelo según los valores del muestreo (iteración) y registrar el resultado
- Repetir el proceso hasta tener una muestra estadísticamente representativa
- Obtener la distribución de frecuencias del resultado de las iteraciones
- Calcular media, desvío.
- Analizar los resultados

Las principales características a tener en cuenta para la implementación o utilización del algoritmo son:

- El sistema debe ser descripto por 1 o más funciones de distribución de probabilidad (fdp)
- Generador de números aleatorios: como se generan los números aleatorios es importante para evitar que se produzca correlación entre los valores muestrales.
- Establecer límites y reglas de muestreo para las fdp: conocemos que valores pueden adoptar las variables.
- Definir Scoring: Cuando un valor aleatorio tiene o no sentido para el modelo a simular.
- Estimación Error: Con que error trabajamos, cuanto error podemos aceptar para que una corrida sea válida?
- Técnicas de reducción de varianza.
- Paralelización y vectorización: En aplicaciones con muchas variables se estudia trabajar con varios procesadores paralelos para realizar la simulación.

Ejemplo

Tenemos la siguiente distribución de probabilidades para una demanda aleatoria y queremos ver que sucede con el promedio de la demanda en varias iteraciones:

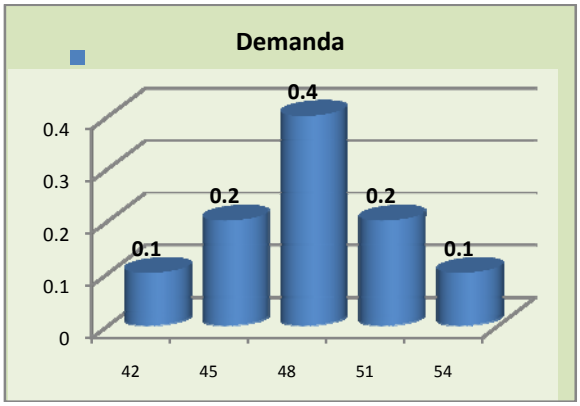

Utilizando la distribución acumulada(F(x) es la probabilidad que la variable aleatoria tome valores menores o iguales a x) podemos determinar cual es el valor obtenido de unidades cuando se genera un número aleatorio a partir de una distribución continua uniforme. Este método de generación de variable aleatoria se llama Transformación Inversa.

Unidades	Frecuencia	Frecuencia Acumulada
42	0.1	0.1
45	0.2	0.3
48	0.4	0.7
51	0.2	0.9
54	0.1	1

Generando los valores aleatorios vamos a ver como se obtiene el valor de la demanda para cada día, interesándonos en este caso como es el orden de aparición de los valores. Se busca el número aleatorio generado en la tabla de probabilidades acumuladas, una vez encontrado (si no es el valor exacto, éste debe se menor que el de la fila seleccionada pero mayor que el de la fila anterior), de esa fila tomada como solución se toma el valor de las unidades (Cuando trabajamos en Excel debemos tomar el límite inferior del intervalo para busca en las acumuladas, para poder emplear la función BUSCARV(), para 42 sería 0, para 43 0,100001 y así sucesivamente). Ejemplo: Supongamos que el número aleatorio generado sea 0,52, ¿a qué valor de unidades corresponde? Nos fijamos en la columna de frecuencias acumuladas, ese valor exacto no aparece, el siguiente mayor es 0,70 y corresponde a 48 unidades.

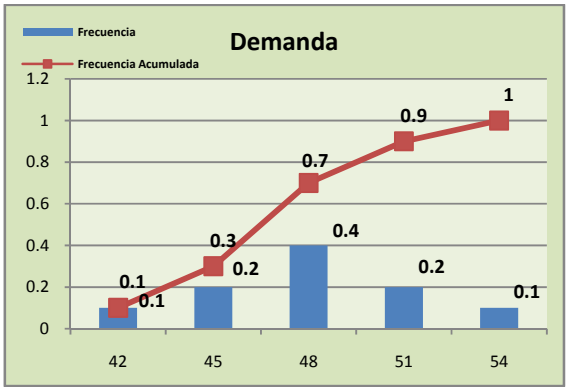

Se puede apreciar mejor en el gráfico, trazando una recta desde el eje de la frecuencia hasta que interseca con la línea de la función acumulada, luego se baja a la coordenada de unidades y se obtiene el valor correspondiente; en este caso 48.

Cuando trabajamos con variables discretas la función acumulada tiene un intervalo o salto para cada variable (para casos prácticos hay que definir los intervalos y luego con una función de búsqueda hallar el valor). Para funciones continuas se puede hallar la inversa de la función acumulada.

De esta forma logramos a partir de la distribución de densidad calcular los valores de la variable aleatoria dada.

Número de Simulación	Números aleatorios	Valor de la Demanda
1	0.92	54
2	0.71	51
3	0.85	51
...	...	...
n	0.46	48

En la siguiente tabla, vemos como a medida que aumenta el numero de simulaciones, el valor simulado se acerca al valor original de la media y desviación estándar, además de la disminución del error típico.

Cantidad de simulaciones	Media	Desvío	Error
10	48.6	3.41	1.08
100	48.12	3.16	0.32
1000	47.87	3.28	0.1
10000	47.87	3.3	0.03

8.4 ¿Qué es la Simulación de Monte Carlo?

La simulación de Monte Carlo es una técnica cuantitativa que hace uso de la estadística y los ordenadores para imitar, mediante modelos matemáticos, el comportamiento aleatorio de sistemas reales no dinámicos (por lo general, cuando se trata de sistemas cuyo estado va cambiando con el paso del tiempo, se recurre bien a la simulación de eventos discretos o bien a la simulación de sistemas continuos).

La clave de la simulación MC consiste en crear un modelo matemático del sistema, proceso o actividad que se quiere analizar, identificando aquellas variables (inputs del modelo) cuyo comportamiento aleatorio determina el comportamiento global del sistema. Una vez identificados dichos inputs o variables aleatorias, se lleva a cabo un experimento consistente en (1) generar – con ayuda del ordenador- muestras aleatorias (valores concretos) para dichos inputs, y (2) analizar el comportamiento del sistema ante los valores generados. Tras repetir n veces este experimento, dispondremos de n observaciones sobre el comportamiento del sistema, lo cual nos será de utilidad para entender el funcionamiento del mismo –obviamente, nuestro análisis será tanto más preciso cuanto mayor sea el número n de experimentos que llevemos a cabo.

Veamos un ejemplo sencillo:

En la imagen inferior se muestra un análisis histórico de 200 días sobre el número de consultas diarias realizadas a un sistema de información empresarial (EIS) residente en un servidor central. La tabla incluye el número de consultas diarias (0 a 5) junto con las frecuencias absolutas (número de días que se producen 0, 1, ..., 5 consultas), las frecuencias relativas (10/200 = 0,05, ...), y las frecuencias relativas acumuladas.

Consultas EIS	Frec.Absoluta (días)	Frecuencia Relativa	Frec.Relativa Acumulada
0	10	0.05	0.05
1	20	0.10	0.15
2	40	0.20	0.35
3	60	0.30	0.65
4	40	0.20	0.85
5	30	0.15	1.00
Total	200	1.00	

Podemos interpretar la frecuencia relativa como la probabilidad de que ocurra el suceso asociado, en este caso, la probabilidad de un determinado número de consultas (así, p.e., la probabilidad de que se den 3 consultas en un día sería de 0,30), por lo que la tabla anterior nos proporciona la distribución de probabilidad asociada a una variable aleatoria discreta (la variable aleatoria es el número de consultas al EIS, que sólo puede tomar valores enteros entre 0 y 5).

Supongamos que queremos conocer el número esperado (o medio) de consultas por día. La respuesta a esta pregunta es fácil si recurrimos a la teoría de la probabilidad.

Denotando por X a la variable aleatoria que representa el número diario de consultas al EIS, sabemos que:

$$E[X] = \sum_{i=1}^{5} x_i P(X = x_i) = 0 \cdot 0.05 + 1 \cdot 0.10 + \cdots + 5 \cdot 0.15 = 2.95$$

Por otra parte, también podemos usar simulación de Monte Carlo para estimar el número esperado de consultas diarias (en este caso se ha podido obtener el valor exacto usando teoría de probabilidad, pero ello no siempre será factible). Veamos cómo:

Cuando se conozca la distribución de probabilidad asociada a una variable aleatoria discreta, será posible usar la columna de frecuencias relativas acumuladas para obtener los llamados intervalos de números aleatorios asociados a cada suceso. En este caso, los intervalos obtenidos son:

- [0.00, 0.05) para el suceso 0
- [0.05, 0.15) para el suceso 1
- [0.15, 0.35) para el suceso 2

- [0.35, 0.65) para el suceso 3
- [0.65, 0.85) para el suceso 4
- [0.85, 1.00) para el suceso 5

El gráfico siguiente nos muestra cada una de las probabilidades sobre el número de consultas. En él, se aprecia claramente la relación existente entre probabilidad de cada suceso y el área que éste ocupa.

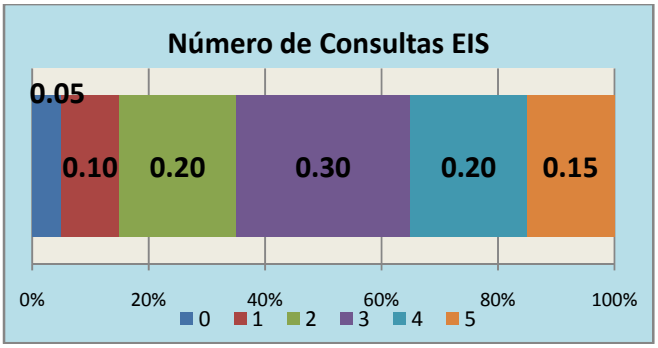

Esto significa que, al generar un número pseudo-aleatorio con el ordenador (proveniente de una distribución uniforme entre 0 y 1), estaremos llevando a cabo un experimento cuyo resultado, obtenido de forma aleatoria y según la distribución de probabilidad anterior, estará asociado a un suceso. Así por ejemplo, si el ordenador nos proporciona el número pseudo-aleatorio 0,2567, podremos suponer que ese día se han producido 2 consultas al EIS.

Asignamos pues la función ALEATORIO a una casilla (la G1 en el caso de la imagen):

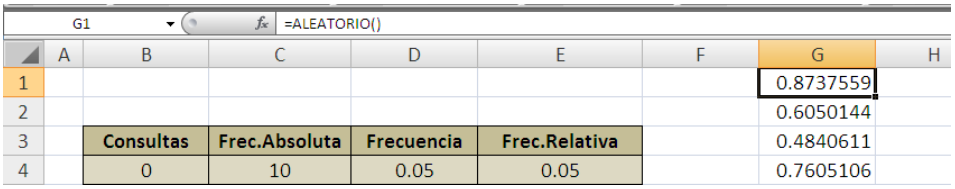

Seleccionando la celda y "arrastrando" con el ratón desde el borde inferior derecho de la misma podemos obtener un listado completo de números pseudo-aleatorios:

A continuación, podemos usar la función SI de Excel para asignar un suceso a cada uno de los números pseudo aleatorios generados (como veremos, otra forma de hacer esta asignación será usando la función BUSCARV):

H1 =+SI(G1<E$4,B$4,SI(G1<E$5,B$5,SI(G1<E$6,B$6,SI(G1<E$7,B$7,SI(G1<E$8,B$8,SI(G1<E$9,B$9,0)))))))

	Consultas	Frec.Absoluta	Frecuencia	Frec.Relativa	G	H
1					0.8570378	5
2					0.1773904	2
3					0.4784497	3
4	0	10	0.05	0.05	0.3269111	2
5	1	20	0.10	0.15	0.9691615	5
6	2	40	0.20	0.35	0.5923416	3
7	3	60	0.30	0.65	0.6636793	4
8	4	40	0.20	0.85	0.9294185	5
9	5	30	0.15	1.00	0.3043955	2
10	Total	200	1.00		0.4576546	3

Repitiendo el proceso de seleccionar y "arrastrar" obtendremos algo similar a:

91	0.7187297	4
92	0.4091178	3
93	0.4351804	3
94	0.0414285	0
95	0.4025115	3
96	0.0759586	1
97	0.5830634	3
98	0.6740602	4
99	0.0366205	0
100	0.8921402	5

Finalmente, usando la función PROMEDIO será posible calcular la media de los valores de la columna H:

I1 =PROMEDIO(H:H)

	Consultas	Frec.Absoluta	Frecuencia	Frec.Relativa	G	H	I
1					0.5005455	3	2.95
2					0.1422303	1	
3					0.641697	3	
4	0	10	0.05	0.05	0.4480453	3	
5	1	20	0.10	0.15	0.4951874	3	

En este caso, hemos obtenido un valor estimado que corresponde exactamente con el valor real anteriormente calculado vía la definición teórica de la media. Sin embargo, debido a la componente aleatoria intrínseca al modelo, normalmente obtendremos valores "cercanos" al valor real, siendo dichos valores diferentes unos de otros (cada simulación proporcionará sus propios resultados). Se puede comprobar este hecho pulsando repetidamente sobre la función F9 (cada vez que se pulsa dicha tecla, Excel genera nuevos valores aleatorios y, por tanto, nuevos valores para la columna H y la casilla I1).

Si en lugar de usar una muestra aleatoria formada por 100 observaciones hubiésemos usado una formada por 10, los valores que obtendríamos al pulsar repetidamente F9 no serían estimaciones tan buenas al valor real. Por el contrario, es de esperar que si hubiésemos usado 1.000 (o mejor aún 10.000) observaciones, los valores que obtendríamos en la casilla I1 estarían todos muy cercanos al valor real.

8.4.1 Simulación MC con Variables Discretas

Veamos un ejemplo algo más complejo del uso de Excel para construir modelos de simulación MC cuando las variables aleatorias sean discretas:

Supongamos que trabajamos en un gran almacén informático, y que nos piden consejo para decidir sobre el número de licencias de un determinado sistema operativo que conviene adquirir – las licencias se suministrarán con los ordenadores que se vendan durante el próximo trimestre, y es lógico pensar que en pocos meses habrá un nuevo sistema operativo en el mercado de características superiores. Cada licencia de sistema operativo le cuesta al almacén un total de 75 dólares, mientras que el precio al que la vende es de 100 dólares. Cuando salga al mercado la nueva versión del sistema operativo, el almacén podrá devolver al distribuidor las licencias sobrantes, obteniendo a cambio un total del 25 dólares por cada una. Basándose en los datos históricos de los últimos meses, los responsables del almacén han sido capaces de determinar la siguiente distribución de probabilidades por lo que a las ventas de licencias del nuevo sistema operativo se refiere:

	A	B	C	D	E	F
1						
2	N°Lic.Vendidas	Probabilidad	Prob.Acum.	Ext.Inf.Intervalo	Ext.Sup.Intervalo	N°Lic.Vendidas
3	100	0.30	0.30	0.00	0.30	100
4	150	0.20	0.50	0.30	0.50	150
5	200	0.30	0.80	0.50	0.80	200
6	250	0.15	0.95	0.80	0.95	250
7	300	0.05	1.00	0.95	1.00	300
8						
9						
10						
11		Costo x Licencia	75	dólares		
12		Ingresos x Lic. Vendida	100	dólares		
13		Ingresos x Lic. Devuelta	25	dólares		
14		Cantidad Lic. a comprar	200	Licencias		

Construimos nuestro modelo usando las fórmulas que se muestran en la figura inferior. En la casilla H2 usaremos la función ALEATORIO para generar el valor pseudo-aleatorio que determinará el suceso resultante; en la celda I2 usamos la función BUSCARV para determinar el suceso correspondiente asociado al valor pseudo-aleatorio obtenido –notar que usamos también la función MIN, ya que en ningún caso podremos vender más licencias que las disponibles. El resto de fórmulas son bastante claras:

	H	I	J	K	L	M	N
1	Num.Aleatorio	Lic.Vendidas	Lic.Devueltas	Costo	Ingreso Ventas	Ingresos Dev.	Beneficios
2	ALEATORIO()	MIN(BUSCARV(H2,$D$3:$F$7,3),$C$14)	$C$14-I2	$C$14*$C$11	I2*C12	J2*C13	L2+M2-K2
3							

En la imagen anterior se muestra cómo construir el modelo con una observación (iteración). A fin de generar nuevas observaciones, deberemos seleccionar el rango H2:N2 y "arrastrar" hacia abajo (tantas casillas como iteraciones deseemos realizar):

	A	G	H	I	J	K	L	M	N
1			Num.Aleatorio	Lic.Vendidas	Lic.Devueltas	Costo	Ingreso Ventas	Ingresos Dev.	Beneficios
2	N°Lic.Vendidas		0.091264748	100	100	15000	10000	2500	-2500
3	100		0.188747486	100	100	15000	2500	20000	7500
4	150		0.841623867	200	0	15000	40000	0	25000
5	200		0.710690837	200	0	15000	0	0	-15000
6	250		0.507409707	200	0	15000	0	0	-15000
7	300		0.557273578	200	0	15000	0	0	-15000
8			0.705056109	200	0	15000	0	0	-15000
97			0.432147687	150	50	15000	0	0	-15000
98			0.011661255	100	100	15000	0	0	-15000
99			0.448965189	150	50	15000	0	0	-15000
100			0.792044861	200	0	15000	0	0	-15000
101			0.725371669	200	0	15000	0	0	-15000

Finalmente, es posible estimar el valor esperado de la variable aleatoria que proporciona los beneficios sin más que hallar la media de las 100 observaciones que acabamos de realizar. Asimismo, usaremos las funciones DESVEST e INTERVALO.CONFIANZA para hallar, respectivamente, la desviación estándar de la muestra obtenida y el intervalo de confianza (a un nivel del 95%) para el valor esperado:

	A	B	C	D
16				
17			Variable Beneficio	
18		media | Media muestral	PROMEDIO(N:N)	
19		Desviación estándar	DESVEST(N:N)	
20		Valor Mín	MIN(N:N)	
21		Valor Máx	MAX(N:N)	
22		Nivel significación (alpha)	0.05	
23		amplitud intervalo de confianza	INTERVALO.CONFIANZA(C22;C19;CONTAR(N:N))	
24		IC para la media a nivel (1-alpha)%	C18-C23	C18+C23

La apariencia final de nuestro modelo será:

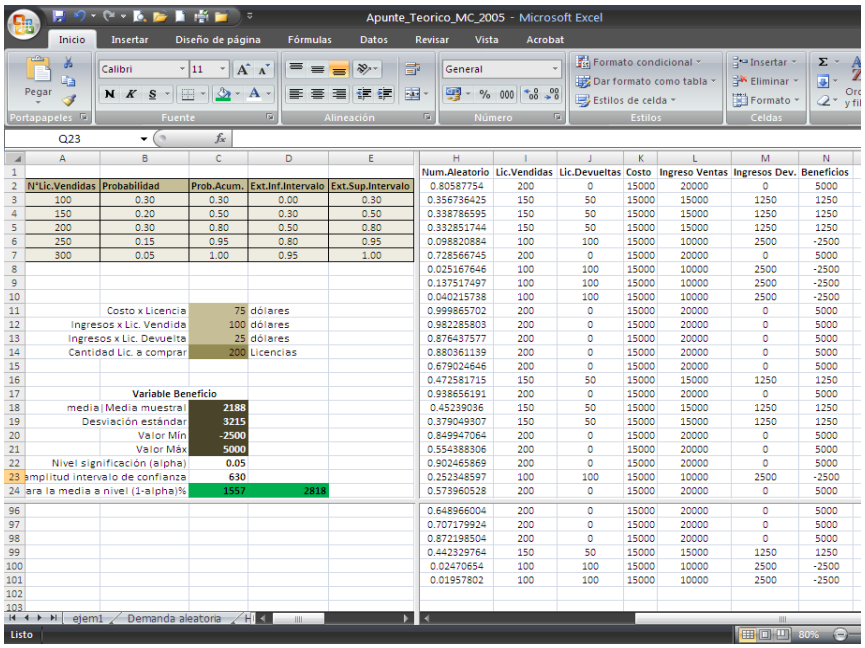

	A	B	C	D	E
1					
2	N°Lic.Vendidas	Probabilidad	Prob.Acum.	Ext.Inf.Intervalo	Ext.Sup.Intervalo
3	100	0.30	0.30	0.00	0.30
4	150	0.20	0.50	0.30	0.50
5	200	0.30	0.80	0.50	0.80
6	250	0.15	0.95	0.80	0.95
7	300	0.05	1.00	0.95	1.00
8					
9					
10					
11		Costo x Licencia	75	dólares	
12		Ingresos x Lic. Vendida	100	dólares	
13		Ingresos x Lic. Devuelta	25	dólares	
14		Cantidad Lic. a comprar	200	Licencias	
15					
16					
17		Variable Beneficio			
18		media | Media muestral	2188		
19		Desviación estándar	3215		
20		Valor Mín	-2500		
21		Valor Máx	5000		
22		Nivel significación (alpha)	0.05		
23		amplitud intervalo de confianza	630		
24		ara la media a nivel (1-alpha)%	1557	2818	

	H	I	J	K	L	M	N
1	Num.Aleatorio	Lic.Vendidas	Lic.Devueltas	Costo	Ingreso Ventas	Ingresos Dev.	Beneficios
2	0.80587754	200	0	15000	20000	0	5000
3	0.356736425	150	50	15000	15000	1250	1250
4	0.338786595	150	50	15000	15000	1250	1250
5	0.332851744	150	50	15000	15000	1250	1250
6	0.098820884	100	100	15000	10000	2500	-2500
7	0.728566745	200	0	15000	20000	0	5000
8	0.025167646	100	100	15000	10000	2500	-2500
9	0.137517497	100	100	15000	10000	2500	-2500
10	0.040215738	100	100	15000	10000	2500	-2500
11	0.999865702	200	0	15000	20000	0	5000
12	0.982285803	200	0	15000	20000	0	5000
13	0.876437577	200	0	15000	20000	0	5000
14	0.880361139	200	0	15000	20000	0	5000
15	0.679024646	200	0	15000	20000	0	5000
16	0.472581715	150	50	15000	15000	1250	1250
17	0.938656191	200	0	15000	20000	0	5000
18	0.45239036	150	50	15000	15000	1250	1250
19	0.379049307	150	50	15000	15000	1250	1250
20	0.849947064	200	0	15000	20000	0	5000
21	0.554388306	200	0	15000	20000	0	5000
22	0.902465869	200	0	15000	20000	0	5000
23	0.252348597	100	100	15000	10000	2500	-2500
24	0.579960528	200	0	15000	20000	0	5000
96	0.648966004	200	0	15000	20000	0	5000
97	0.707179924	200	0	15000	20000	0	5000
98	0.872198504	200	0	15000	20000	0	5000
99	0.442329764	150	50	15000	15000	1250	1250
100	0.02470654	100	100	15000	10000	2500	-2500
101	0.01957802	100	100	15000	10000	2500	-2500
102							
103							

A partir del modelo anterior es posible también realizar "what-if" análisis (análisis de escenarios o preguntas del tipo "¿qué pasaría si cambiamos tal o cual input?"). Para ello es suficiente con ir cambiando los valores de las celdas C11:C14 (inputs del modelo en este ejemplo). Asimismo, podemos ampliar fácilmente el número de iteraciones (observaciones muestrales) sin más que repetir los procesos de seleccionar y "arrastrar".

En el caso actual, hemos optado por tomar 1.000 iteraciones para cada una de los posibles inputs asociados a la cantidad de pedido (estos posibles inputs son: 100, 150, 200, 250, y 300). Si se realizase el experimento, se obtendrían unos resultados similares a los que se muestran a continuación (ya que 1.000 es un número ya bastante considerable para este ejemplo):

	Resultados para n=1000 iteraciones			
N° Licencias	Benef.Medio	Desv.Est.	Intervalo confianza 95%	
100	2500	0	2500	2500
150	2569	1743	0	3750
200	2079	3250	-2500	5000
250	333	4154	-5000	6250
300	-1868	4555	-7500	7500

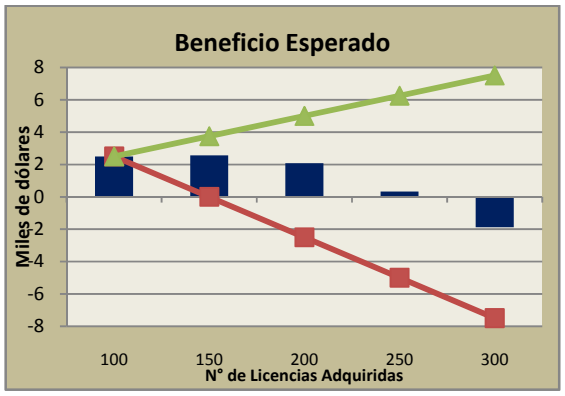

A partir de los resultados, parece claro que la decisión óptima es hacer un pedido de 150 unidades, ya que con ello se consigue el beneficio máximo.

8.4.2 Generación de Números Aleatorios Provenientes de Otras Distribuciones

Las últimas versiones de Excel incorporan un Add-In llamado Análisis de datos. Este complemento proporciona nuevas funcionalidades estadísticas a la hoja de cálculo. Entre ellas, nos interesa destacar la de Generación de números aleatorios:

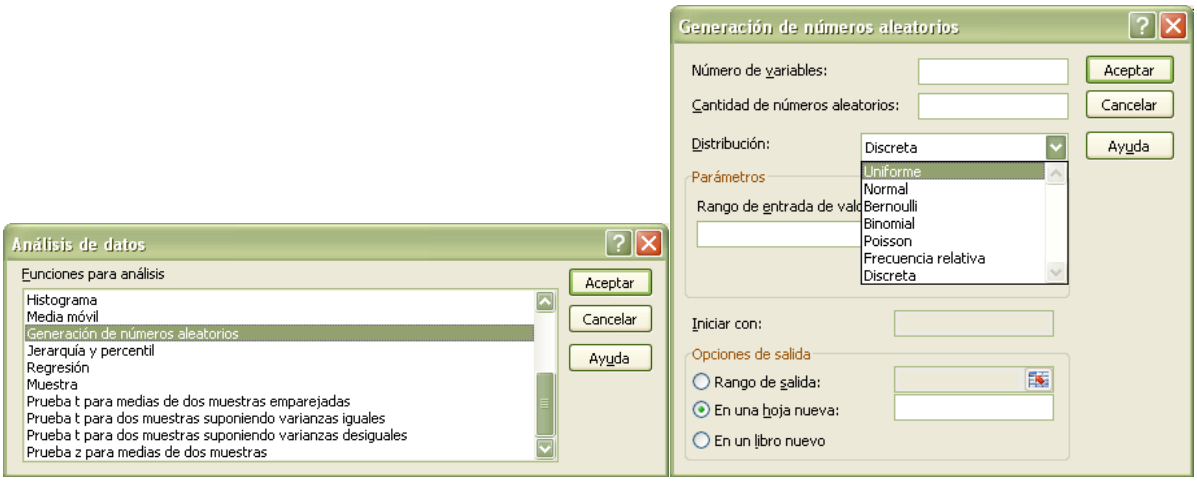

Con esta opción, es posible generar fácilmente observaciones provenientes de diversas distribuciones de variable discreta (Bernoulli, Binomial, Poisson, Frecuencia relativa, y Discreta) o de variable continua (Uniforme y Normal).

Independientemente del complemento Análisis de datos, es posible usar un resultado muy conocido de la teoría estadística, llamado método de la transformada inversa, para derivar las fórmulas que permiten obtener valores pseudo-aleatorios provenientes de distribuciones como la Weibull o la Lognormal.

En la tabla siguiente se muestran algunas fórmulas que, implementadas en celdas de Excel, nos permiten obtener valores pseudo-aleatorios de algunas de las distribuciones continuas más usadas:

Distribución	Parámetros	Formula Excel
Exponencial	Media = b	= -LN(ALEATORIO())*b
Weibull	Escala = b Forma = a	= b*(-LN(ALEATORIO())^(1/a)
Normal	Media = μ Desv. Estandar = σ	= DISTR.NORM.INV(ALEATORIO(),μ, σ)
Lognormal	Media de Ln(X) = μ Desv. Estandar de Ln(X) = σ	= DISTR.LOG.INV(ALEATORIO(),μ, σ)
Uniforme entre a y b	Extremo inferior = a Extremo superior = b	= a+(b-a)*ALEATORIO()

Añadir, finalmente, que es relativamente sencillo implementar funciones VBA que, haciendo uso del método de la transformada inversa o de otros métodos similares, permita la generación de valores provenientes de casi cualquier distribución teórica.

8.4.3 Simulación MC con Variables Continuas

Como hemos comentado, es posible usar las fórmulas anteriores para generar, a partir de la función ALEATORIO(), valores pseudo-aleatorios provenientes de otras distribuciones

continuas. En las páginas siguientes, veremos dos ejemplos de modelos que hacen uso de la distribución normal (la distribución estadística más importante y utilizada):

Ejemplo: Tiempo de consultas a servidores en paralelo

Supongamos que desde un ordenador cliente se realiza consultas SQL a bases de datos situadas en dos servidores distintos. Nuestro objetivo será estimar el tiempo esperado (tiempo medio) que deberemos esperar para recibir la respuesta de ambos servidores. Dada la complejidad de la consulta que queremos realizar, y basándonos en experiencias anteriores, se calcula que el tiempo necesario para que cada uno de los servidores responda a la misma sigue una distribución normal con los parámetros (media y desviación estándar, en minutos) que se indican a continuación:

	A	B	C	D	E
1					
2			Distribución	Media (min)	Des.Est.(min)
3		Servidor 1	Normal	20	3.4
4		Servidor 2	Normal	22	2.6
5					

Pediremos a Excel que genere valores pseudo-aleatorios provenientes de dichas distribuciones. Asimismo, usaremos la función MAX para obtener el tiempo de respuesta (que será el máximo de los tiempos de respuesta de cada servidor), y la función SI para determinar qué servidor ha sido el más rápido en responder:

	G	H	I	J
1				
2	Servidor 1	Servidor 2	Total	Servidor más rápido
3	=DISTR.NORM.INV(ALEATORIO(),$D$3,$E$3)	=DISTR.NORM.INV(ALEATORIO(),$D$4,$E$4)	=MAX(G3:H3)	=SI(G3<H3,1,2)
4				

Usaremos también las funciones CONTAR y CONTAR.SI para contar el número de iteraciones y el número de veces que un servidor es más rápido que el otro:

	A	B	C	D	E
5					
6				Frecuencia	Porcentaje
7			Total iteraciones:	=CONTAR(J:J)	
8			S1+rápido	=CONTAR.SI(J:J,1)	
9			S2+rápido	=CONTAR.SI(J:J,2)	
10					
11			tiempo medio:	=PROMEDIO(I:I)	minutos
12			Desv. Est.	=DESVEST(I:I)	minutos
13			95% para Total Esperado	=$D$11-INTERVALO.CONFIANZA(0.05,$D$12,$D$7)	=$D$11+INTERVALO.CONFIANZA(0.05,$D$12,$D$7)
14					

Finalmente, las funciones PROMEDIO, DESVEST, e INTERVALO.CONFIANZA nos servirán para obtener, respectivamente, el tiempo muestral medio (esperado) de respuesta, la desviación estándar de la muestra (observaciones que generaremos), y un intervalo de confianza, a un nivel del 95%, para el tiempo medio (este intervalo nos permitirá saber si nuestra estimación es buena o si, por el contrario, necesitaremos más iteraciones).

Una vez introducidas las fórmulas anteriores, bastará con seleccionar y "arrastrar" hacia abajo el rango de celdas G3:J3, con lo que se generarán nuevas iteraciones. En la imagen siguiente se muestra el resultado obtenido al generar 2.077 iteraciones. Observar que el tiempo medio estimado de respuesta es de 22,98 minutos, y podemos asegurar, con un nivel de confianza del 95%, que dicho tiempo medio estará entre 22,88 y 23,08 minutos.

	A	B	C	D	E	F	G	H	I	J
1							Tiempo de respuesta (minutos)			Servidor
2			Distribución	Media (min)	Des.Est.(min)		Servidor 1	Servidor 2	Total	más rápido
3		Servidor 1	Normal	20	3.4		20.15305038	25.11791941	25.11791941	1
4		Servidor 2	Normal	22	2.6		22.65458616	19.16397126	22.65458616	2
5							22.60990307	21.80531011	22.60990307	2
6				Frecuencia	Porcentaje		18.79038276	28.69129545	28.69129545	1
7			Total iteraciones:	2077	100%		21.49853977	24.50314263	24.50314263	1
8			S1+rápido	1405	68%		20.35150604	24.55460169	24.55460169	1
9			S2+rápido	672	32%		21.36340065	20.81665673	21.36340065	2
10							23.28813528	20.56397305	23.28813528	2
11			tiempo medio:	22.98	minutos		22.58088003	20.15466834	22.58088003	2
12			Desv. Est.	2.33	minutos		24.43841282	12.81669089	24.43841282	2
13			95% para Total Esperado	22.88	23.08		17.01920442	23.4059311	23.4059311	1
14							23.13072769	20.40889703	23.13072769	2
15							23.00776843	21.63734494	23.00776843	2

Finalmente, se observa también que el servidor 1 ha respondido más rápido que el servidor 2 en el 68% de las iteraciones.

Ejemplo: Inversión inicial y flujo de caja

Consideremos ahora un nuevo problema: supongamos que disponemos de un capital inicial de 250 dólares que deseamos invertir en una pequeña empresa. Supondremos también que los flujos de caja -tanto los de entrada como los de salida- son aleatorios, siguiendo éstos una distribución normal.

	A	B	C	D	E
1					
2		Capital inicial:	250 dólares		
3					
4		Flujo de Caja Enero:	Distribución	Media	Des.Est
5		Entrante:	normal	500	125
6		Saliente:	normal	400	100

Para el primer mes, el valor esperado del flujo de entrada es de 500 Euros, mientras que el valor esperado para el flujo de salida es de 400 Euros. En meses posteriores, el valor esperado será el valor obtenido para en el mes anterior. Por su parte, las desviaciones estándar valdrán, en todos los casos, un 25% del valor medio (esperado) asociado. En base a lo anterior, podemos construir un modelo como se muestra en las siguientes imágenes:

	G	H	I
1	FLUJO ENERO		
2	Entrante	Saliente	Neto
3	=DISTR.NORM.INV(ALEATORIO(),$D$5:$E$5)	=DISTR.NORM.INV(ALEATORIO(),$D$6:$E$6)	=$C$2+G3-H3
4			

	J	K	L
1	FLUJO FEBRERO		
2	Entrante	Saliente	Neto
3	=DISTR.NORM.INV(ALEATORIO(),G3,0.25*G3)	=DISTR.NORM.INV(ALEATORIO(),H3,0.25*H3)	=I3+J3-K3

P13

	M	N	O
1	FLUJO MARZO		
2	Entrante	Saliente	Neto
3	=DISTR.NORM.INV(ALEATORIO(),J3,0.25*J3)	=DISTR.NORM.INV(ALEATORIO(),K3,0.25*K3)	=L3+M3-N3

	A	B	C	D
9				
10		Iteraciones:	=CONTAR(G:G)	
11		Flujo Final Max:	=MAX(O:O)	Dólares
12		Flujo Final Min:	=MIN(O:O)	Dólares
13		Capital Final Esperado:	=PROMEDIO(O:O)	Dólares
14		IC 95%:	=$C$13-INTERVALO.CONFIANZA(0.05,DESVEST($O:$O),$C$10)	=$C$13+INTERVALO.CONFIANZA(0.05,DESVEST($O:$O),$C$10)
15				

Seleccionando y "arrastrando" hacia abajo el rango G3:O3, hemos obtenido los siguientes resultados para 5.859 iteraciones:

	A	B	C	D	E	F	G	H	I	J	K	L	M
1							FLUJO ENERO			FLUJO FEBRERO			FL
2		Capital inicial:	250	dólares			Entrante	Saliente	Neto	Entrante	Saliente	Neto	Entrante
3							697.8109616	654.168814	293.6421478	738.4641824	657.823554	374.2827767	611.4567171
4		Flujo de Caja Enero:	Distribución	Media	Des.Est		348.9590664	460.365521	138.5935457	274.6139552	426.174858	-12.9673567	247.0087594
5		Entrante:	normal	500	125		664.564793	375.721365	538.8434285	725.1068036	282.593918	981.3563141	1002.015905
6		Saliente:	normal	400	100		485.8108861	533.127626	202.6832598	648.0196248	535.648152	315.054733	626.8534195
7							452.5422642	496.045853	206.496411	399.251163	454.958403	150.789171	564.2599388
8							624.2740893	539.091626	335.1824634	582.0903755	651.229164	266.0436745	581.8849784
9							264.001856	440.5857	73.41615603	220.485057	532.868267	-238.967054	238.6511142
10		Iteraciones:	5859				651.9151018	429.034769	472.8803332	627.3826174	271.447338	828.8156129	631.7226055
11		Flujo Final Max:	3535.00	Dólares			394.4035424	532.29396	112.1095825	392.2036372	287.596516	216.7167039	358.7233136
12		Flujo Final Min:	-1841.95	Dólares			349.6454072	503.241611	96.40379607	334.1830917	507.804567	-77.2176794	309.8959117
13		Capital Final Esperado:	542.90	Dólares			608.8844829	479.391083	379.4933998	367.3932563	512.759938	234.1267183	291.7476247
14		IC 95%:	527.37	558.44			511.5463044	572.521788	189.0245167	595.3105034	765.385763	18.94925726	807.6739209
15							590.5079282	490.356451	350.1514771	819.7429711	560.600464	609.2939839	628.7899163

Observamos que el valor esperado para el capital final es de unos 543 dólares, y que podemos afirmar, con un nivel de confianza del 95%, que dicho valor estará entre 527 y 558 dólares.

8.5 Actividades para el Aprendizaje.

Luego de visitar estas direcciones de páginas web, elaborar un resumen y/o desarrollar los ejercicios propuestos para el tema correspondiente:

Una Aplicación del Método de Monte Carlo en el Análisis de Riesgo de Proyectos: Su automatización a través de una planilla de cálculo.
http://www.abcbolsa.com/montecarlo_excel_cyta1.htm

El método de Monte Carlo: http://www.monografias.com/trabajos12/carlo/carlo.shtml

Simulación: Excel Avanzado, Macro, funciones. http://trucosexcel.blogspot.com/

Resolver los ejercicios al capitulo correspondiente:

Cátedra de Métodos Cuantitativos para los Negocios.
http://www.unsa.edu.ar/mcneco/mcn_tps.html

Programación Matemática
http://www.uv.es/~sala/programacion.htm

Bienvenidos a los cursos del Área de Operaciones – Descargar ejercicios:
http://ucreanop.org/descarga_ejercicios.php